

RELATÓRIO P2- CLASSIFICAÇÃO DO DATASET IRIS

Grupo 09 - Felipe Estevo Freitas RA: 1990153 | Marcela Kawamoto RA: 2224453

1. OBJETIVO DO PROJETO

O objetivo do projeto é classificar flores Iris nas espécies setosa, versicolor e virginica, usando quatro medidas: comprimento da sépala, largura da sépala, comprimento da pétala e largura da pétala. O trabalho foi atualizado para a P2, mantendo o mesmo tema da P1 e corrigindo os pontos indicados na devolutiva.


2. MELHORIAS FEITAS PARA A P2

A versão da P1 já possuía código funcional, mas o notebook estava pouco explicado e o relatório não estava totalmente coerente com os resultados. Na P2, o notebook foi reorganizado em etapas, recebeu textos explicativos, teve os gráficos interpretados e passou a justificar a escolha do modelo final com base nas métricas de validação cruzada.

Também foram atualizados o relatório, o salvamento do modelo final e a preparação da aplicação Streamlit, garantindo que notebook, relatório, modelo salvo e aplicativo usem os mesmos resultados.

3. ANÁLISE EXPLORATÓRIA DOS DADOS

O dataset Iris possui 150 registros, divididos igualmente entre as três espécies, com 50 exemplos para cada classe. Isso mostra que o conjunto está balanceado, o que ajuda a evitar favorecimento de uma espécie durante o treinamento.



A análise dos gráficos mostrou que as medidas de pétala separam melhor as espécies do que as medidas de sépala. A setosa aparece bem separada, enquanto versicolor e virginica possuem maior proximidade, o que explica possíveis confusões entre essas duas classes.

4. PRÉ-PROCESSAMENTO E MODELOS UTILIZADOS

O dataset foi carregado pelo scikit-learn, sem depender de arquivo CSV externo. Foram verificados valores ausentes, duplicados e tipos de dados. Em seguida, os dados foram divididos em treino, validação e teste, na proporção 60%, 20% e 20%, com estratificação para preservar o equilíbrio das classes.

Foram comparados três classificadores: KNN, Regressão Logística e Random Forest. A normalização foi aplicada por meio de Pipeline nos modelos que dependem da escala dos dados. A avaliação utilizou StratifiedKFold com 5 divisões e métricas macro, principalmente o F1 Score Macro.

Modelo	Acurácia	Precisão Macro	Recall Macro	F1 Score Macro
Logistic Regression	0,9583	0,9626	0,9583	0,9580
Random Forest	0,9500	0,9552	0,9500	0,9497
KNN	0,9417	0,9478	0,9417	0,9413

Com base na validação cruzada, a Regressão Logística foi escolhida como modelo final, pois apresentou o melhor F1 Score Macro médio. Essa escolha corrige a inconsistência da P1, em que o relatório indicava outro modelo sem justificativa suficiente.


5. AVALIAÇÃO DO MODELO FINAL

Após a escolha do modelo final, a Regressão Logística foi treinada com os dados de treino e validação juntos. Depois, foi testada em dados separados, que não haviam sido usados na escolha do modelo.

Métrica	Resultado
Acurácia	0,9333
Precisão Macro	0,9444

Recall Macro	0,9333
F1 Score Macro	0,9327


O modelo acertou 28 das 30 amostras do conjunto de teste. A matriz de confusão mostra que setosa e versicolor foram classificadas corretamente em todos os casos. Os dois erros ocorreram em amostras reais de virginica, que foram previstas como versicolor.



6. INTERPRETAÇÃO DOS RESULTADOS

O PCA foi usado apenas para visualização, mostrando a setosa bem separada e versicolor próxima da virginica. A análise de importância das variáveis, feita com Random Forest como apoio interpretativo, indicou que largura e comprimento da pétala foram as variáveis mais relevantes.

7.
E



**MODELO SALVO
APLICAÇÃO**

O modelo final foi salvo em formato .joblib e .pkl, junto com os nomes das classes. Esses arquivos são usados pela aplicação Streamlit para carregar o mesmo modelo treinado no notebook e exibir o nome correto da espécie prevista.

8. CONCLUSÃO

A Regressão Logística foi escolhida como modelo final por apresentar o melhor F1 Score Macro médio na validação cruzada.

Os resultados indicam bom desempenho geral do modelo. A espécie setosa é a mais fácil de classificar, enquanto versicolor e virginica são mais próximas e podem gerar confusões. Assim, o projeto atende às etapas essenciais da atividade, mantendo coerência entre notebook, relatório, modelo salvo e aplicação Streamlit.